№	ссылка на статью	библиография	summary	статья полезна?	полезные моменты из статьи (если она полезна)
1	Yuan h., et al., 2024.	Yuan H. et al. The high dimensional psychological profile and cultural bias of ChatGPT. arXiv [Электронный ресурс].	Авторы анализируют психологический и культурный портрет ChatGPT по большому количеству параметров и показывают, что модель существенно отклоняется от человеческих норм (отличаются ценности, наблюдаются культурные смещения и в ряде задач чат принимает решения, основанные на стереотипах) Главный вывод: несмотря на “человеко-подобность” общения, модель не обладает человеческим психологическим профилем и требует осторожного использования в социальных целях.	да	Статья очень хорошо подходит к нашей теме. Что сделали авторы (и что будет полезно нам) - ChatGPT 84 оценки (измерения) психологического профиля (разные аспекты: личность, убеждения, установки и пр.) — psychological traits - 13 измерений культурных ценностей — cultural values - 8 задач принятия решений, в которых ChatGPT взаимодействовал (или моделировал взаимодействие) с “человеками из разных стран/регионов” для проверки наличия культурных стереотипов или предвзятости модели — cultural biases
2	Liu H. et al., 2025.	Liu H. et al. Towards realistic evaluation of cultural value alignment in large language models:	Статья предлагает новый способ оценивать, насколько большие языковые модели соотносятся с культурными ценностями людей —	да	В статье используются настоящие социальные опросы (2018–2023), включая World Values Survey by Haerpfer, Inglehart, Moreno, Welzel, et al.

		Diversity enhancement for survey response simulation //Information Processing & Management. – 2025. – Т. 62. – №. 4. – С. 104099.	особенно в США и Китае. Создается Diversity-Enhanced Framework (DEF) — фреймворк, который генерирует разнообразные ответы модели так, будто в опросе участвуют разные виртуальные респонденты (управление вариативностью ответов LLM). А именно. Методы: - Манипуляция памятью (модель забывает предыдущие вопросы, имитируя человеческую память) - Изменение промпта (city-level simulation) — симуляция ответов жителей США/Китая - Параметры (um_beams, sampling) задаются случайно, что модель рассуждала по-разному В статье ставятся задачи понять - насколько LLM отражают культурные ценности (value alignment) - почему они расходятся с человеческими ценностями - как именно их поведение меняется между культурами (США vs Китай)		(2022), the General Social Survey (Smith, Marsden, Hout, & Kim, 2012) и the Chinese General Social Survey для оценки ценностей моделей и сравнения с человеческими. Очень интересные подходы к генерации ответов на вопросы (симуляция, манипулирование памятью, рандомайзер параметров) В целом рекомендую к прочтению, возможно, удастся еще больше полезного почерпнуть.

			Разработанные для оценки метрики: - Preference distribution (насколько распределение ответов модели близко к распределению человеческих. - Cultural variation map (отражает, как модель различает культуры) - Preference bias (анализ гендерных и возрастных смещений) - Insensitivity measurement (насколько непоследовательны/ошибочны объяснения модели) Основные выводы: современные LLM пока неточно соответствуют человеческим ценностям, особенно в межкультурных контекстах. Лучший результата продемонстрировала Mistral.		
3	Shen et al., 2024	Shen W. et al. Small llms are weak tool learners: A multi-llm agent //arXiv preprint arXiv:2401.07324. – 2024.	Вместо одной мультифункциональной LLM, авторы предлагают разделить три роли, и чтобы каждая роль была у одного агента: - Planner — планирование - Caller — непосредственный вызов инструмента (API,	5…	Наверное, не очень подходит, если мы не собираемся реализовывать свою мультиагентную систему, создавай агента, способного обращаться к внешним базам данных и инструментам мы хотим использовать методологию

			внешняя функция, код) - Summarizer — формирование итогового ответа Стратегия дообучения: - Global fine-tuning — есть базовая LLM, которая обучается на всем датасете без разделения задач, чтобы понять общую логику агента. - Local fine-tuning — делают три копии этой модели и дообучают каждую на её конкретную роль		для наших целей
4	Magister L. C. et al., 2025	Magister L. C. et al. On the way to llm personalization: Learning to remember user conversations //Proceedings of the First Workshop on Large Language Model Memorization (L2M2). – 2025. – С. 61-77.	Предлагается новый подход к персонализации LLM, который учитывает стиль, отдельные предпочтения пользователя и (собственно новое) позволяет модели запоминать целиком прошлые пользовательские разговоры и использовать это знание в будущем. Главная цель — научить LLM параметрически хранить содержание предыдущих диалогов с конкретным пользователем без RAG, внешних баз данных и длинных контекстов, которые	да	Метод parametric knowledge injection (способ внедрять новое знание внутрь параметров LLM, то есть в саму модель, чтобы она знала что-то без необходимости давать это в контексте, то есть извне, или извлекать из внешней базы) Из минусов — в статье акцент именно на запоминание диалогов с пользователем как источника знаний, а не на предпочтениях/эмоциональном портрете и т.п..

			ухудшают качество ответов, выдаваемых моделью. В статье предствален PLUM — Pipeline for Learning User Conversations in LLMs — метод, в основе которого Data Augmentation (генерация данных для обучения) и finetuning (LoRA + Weighted CE Loss)		* parametric → хранится в параметрах, то есть можно добавить при помощи fine-tuning или PEFT (Parameter-Efficient Fine-Tuning, класс методов параметр-эффективного дообучения больших языковых моделей), LoRA (самый популярный метод из PEFT.), Adapter-based injection
5	Qiu Y. et al., 2025	Qiu Y. et al. Measuring what makes you unique: Difference-aware user modeling for enhancing llm personalization //arXiv preprint arXiv:2503.02450. – 2025.	В статье предлагается новый метод персонализации — Difference-aware Personalization Learning (DPL), цель которого — адаптировать модели таким образом, чтобы их ответы соответствовали уникальным предпочтениям человека. В отличие от традиционных методов, которые уфитывают историю диалога (memorize-then-inject), но игнорируют сравнение между пользователями, авторы предлагают DPL — подход, помогающий извлекать межпользовательские различия для усиления персонализации LLM. DPL выбирает репрезентативных пользователей для сравнения и вводит	5…	Что может быть полезно: сама идея о том, чтобы для персонализации нужно не только учитывать психологический портрет человека, но и сравнивать его с другими для лучшей настройки. Авторы также ссылаются на исследования по психологии, в которых подчеркивается важность различий для уникальности людей: Snyder and Fromkin (1977, 2012); Irmak et al. (2010) Почему может не подойти: тут решается немного другая задача (отталкиваются не от самой модели и ее особенностей, а от преференций конкретного человека)

			предлагает стандарт для обнаружения релевантных различий, которые затем используются для кастомизации. . Отличия между пользователями измеряются по writing style (стиль письма), emotional style (тональность), semantic style (семантика)		
6	Zhao X. et al., 2025	Zhao X. et al. NextQuill: Causal Preference Modeling for Enhancing LLM Personalization //arXiv preprint arXiv:2506.02368. – 2025.	NextQuill — новая система персонализации LLM, основанная на каузальном моделировании предпочтений (т.е. ее задача — вычислить каузальный эффект предпочтений — какие части пользовательской истории и насколько влияют на предсказания модели)	нет	— (здесь речь именно про персонализацию через учет истории диалога с пользователем)
7	Galitsky B. A., 2024	Galitsky B. A. Llm-based personalized recommendations in health. – 2024.	В статье предлагается подход с meta-prompting и абдуктивным рассуждением, который формирует индивидуальные ответы на основе обезличенных данных пользователя	5…	Здесь можно посмотреть небольшое овервью про персонализацию (2. Personalization scenarios), но это опять же не совсем та персонализация, что нам нужна
8	Mendoza R. et al., 2024 пдф	Mendoza R. et al. Adaptive self-supervised learning strategies for dynamic on-device llm personalization //arXiv	Метод, который позволит LLM «подстраиваться» под пользователя динамически, прямо на устройстве, без необходимости собирать большие размеченные датасеты	нет	

	версия	preprint arXiv:2409.16973. – 2024	ASLS — архитектура, которая обеспечивает персонализацию LLM на основе самообучения (self-supervised) и онлайн-адаптации. 1. User Profiling Layer — собирает информацию о поведении пользователя и формирует «профиль». 2. Neural Adaptation Layer — использует этот профиль для адаптации параметров модели в реальном времени.		
9	Liu Y. F. et al., 2025	Liu Y. F. et al. From Five Dimensions to Many: Large Language Models as Precise and Interpretable Psychological Profilers //arXiv preprint arXiv:2511.03235. – 2025.	может ли модель ИИ (LLM) — на минимальной информации — восстановить внутреннюю психологическую структуру человека, а не просто предсказывать отдельные черты? Они дали LLM ответы 816 человек на опросник Big Five. По 20 численным значениям (Big Five) предсказать ответы на 9 других, более сложных и разнообразных шкал.	5…	- ответы стабильны, доказательство - анализ reasoning, но он в статье раскрывается немного с другой точки зрения - Experiment 2: Deconstructing the Reasoning Mechanism, я бы только эту часть почитала бы, чтобы посмотреть как работает у моделей reasoning именно с психологической точки зрения и на сколько правильно она делает

			- LLM могут, с очень высокой точностью, реконструировать общую психологическую структуру человека (номотетическую сеть) - Специальные модели-аннотаторы читают рассуждения и пытаются понять: какие пункты Big Five (из 20) модель реально использовала при формировании ответа и насколько каждый пункт был важен, а потом это сравнивается с классической регрессионной моделью (Bayesian Ridge Regression		выводы
10	Pellert M. et al., 2024 пдф формат	Pellert M. et al. Ai psychometrics: Assessing the psychological profiles of large language models through psychometric inventories //Perspectives on Psychological Science. – 2024. – Т. 19. – №. 5. –	Авторы предлагают, что стандартные психометрические тесты, можно адаптировать для оценки аналогичных “психологических профилей” у больших языковых моделей Предпосылка: при обучении на огромных корпусах текстов,	5…	- есть исторический контекст, небольшое овервью, возможности ЛЛМ, возможности оценки и т.д. - очень большая вводная часть, можно использовать как бриф овервью - обнаружились различия между

		С. 808-826.	порождённых людьми, LLM «усваивают осадки» — черты личности, ценности, убеждения и предубеждения множества авторов. Эти «усвоенные» черты потенциально проявляются в поведении модели особенно при применении в реальных задачах Поэтому цель — выявить их «личностные» и ценностные профили, а также возможные предубеждения. Только Берт Big Five, Portrait Value Questionnaire (PVQ-RR), Moral Foundations Questionnaire, Gender/Sex Diversity Beliefs Scale (GSDB; Schudson & van Anders, 2022), Short Dark Tetrad questionnaire (SD4 / “тёмная тетрада”)		ответами на мужскую и женскую версии — что может быть индикатором гендерных предвзятостей модели. И в еще некоторых тестах проявлялась гендерная предвзятость, стереотипность, которую авторы обосновываяют теми самыми “осадками” - Methods for model assessments: Masked-language prediction (“I feel very [MASK] today” - модель выбирает слово, отражающее её “реакцию” на утверждение из опросника), Next-word prediction (I am feeling very…”), Zero-shot classification (Модель получает утверждение + набор возможных ответов)
11	Huang J. et al., 2023-1	Huang J. et al. On the humanity of conversational ai: Evaluating the	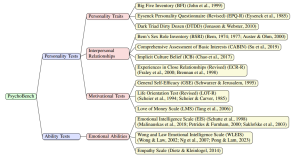	да	Важный момент - Beyond GPT-4, we also set up a jailbroken GPT-4 to bypass the safety alignment protocol of GPT-4, using a recent method named CipherChat

		psychological portrayal of llms //The Twelfth International Conference on Learning Representations. – 2023.	PSYCHOBENCH - первый систематический набор психологических тестов для ИИ могут ли LLM демонстрировать черты, похожие на человеческие: личность, темперамент, эмоции? авторы разработали инструмент — психологическое «тестирование» моделей, аналогичное тому, как психологи тестируют людей. 1. У LLM проявляются устойчивые «психологические профили». 2. Разные модели демонстрируют разные «личности». 3. Поведение моделей можно измерять с помощью психологических шкал. 4. GPT-4 после снятия ограничений (jailbreak) ведёт себя иначе		(Yuan et al., 2024). To acquire responses that reflect the true thoughts of GPT-4, we apply a Caesar cipher with shift three on its prompts. Они ставили температуру по 0, лама - 0.1, т.к. там невозможен 0 A Likert level - a common survey tool measuring attitudes or opinions from one extreme to another (e.g., "Strongly Disagree" to "Strongly Agree"). мужское\женское

12	Huang J. et al., 2023-2	Huang J. et al. Revisiting the reliability of psychological scales on large language models //arXiv preprint arXiv:2305.19926. – 2023.	Авторы пытаются выяснить, насколько надёжно можно применять психологические шкалы, созданные для людей, к большим языковым моделям. В роли шкалы используется Big Five Inventory (BFI) — OCEAN. Выводы статьи: 1. В большинстве случаев LLM давали довольно устойчивые и последовательные ответы на BFI — несмотря на большие изменения (язык, формулировки, формат и пр.) 2. LLM способны выдавать стабильные “личностные профили” 3. Вариативность ответов LLM был значительно меньше, чем у человеческих выборок 4. С помощью определённых инструкций (prompt-инструкций) можно “задать” LLM желаемую “личность” — т.е. они способны симулировать разные “типы” личности по BFI. 5. Разграничение надежности и	да	Главный вопрос - выдают ли модели стабильно одинаковый результат при разных формулировках теста? Это как раз тот вопрос, который мы задавали, сколько раз получать ответ, как влияет язык, инструкция и т.д. 2500 различных configurations для тестирования — они варьировали: формулировку инструкции, перефразировка вопросов, язык, формат вариантов ответов, порядок вариантов. В нашем случае именно этот аспект интересен, т.к. можно посмотреть как можно преподносить вопросы. Они не только меняли “настройки” вопросов, но еще и создавали контекст, например говорили модели, что она экстраверт и модель подгоняла ответы под этот тип. Так же интересно, что они меняли формулировку вопроса, и в нашем случае это может разговорить модель. то есть они не всегда напрямую задавали вопрос (Assigning a Personality). То есть это статья нам может помочь на начальном уровне

			валидности		тестирования, понять как какие-настройки влияют и т.д.
13	LoRA: Low-Rank Adaptation of Large Language Models	Hu E. J. et al. Lora: Low-rank adaptation of large language models //ICLR. – 2022. – Т. 1. – №. 2. – С. 3.	Для адаптации ллм моделей можно воспользоваться fine-tuning, но этот метод полностью меняет веса модели, а это дорого, требует большой вычислительной мощности и т.д. Поэтому авторы предлагают Low-Rank Adaptation. LoRA предлагает заморозить исходные веса LLM и обучать только небольшую добавочную матрицу, которая моделируется через низкоранговое разложение. Исходная матрица весов W не модифицируется, поэтому можно легко переключаться на разные задачи, просто заменяя LoRA-слои. - LoRA достигает качества, сопоставимого с полным fine-tuning.	да	Статья поможет разобраться в том, что такое ЛоРА и как это можно использовать в нашем иссдледовании, так как этот способ максимально нам подходит.
14	QLoRA: Efficient Finetuning of Quantized LLMs			н…	

15	Augmenting Language Models with Long-Term Memory			H…	