Патопсихологический портрет LLM

Фаттахова Анна,
Федоринина Полина

Персонализация

LoRA: Low-Rank Adaptation of Large Language Models

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen

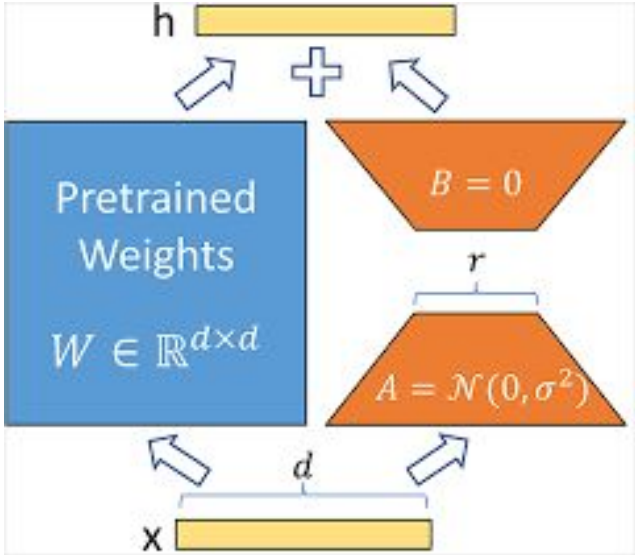

Low-Rank Adaptation (LoRA) предлагает заморозить исходные веса LLM и обучать только небольшую добавочную матрицу, которая моделируется через низкоранговое разложение. Исходная матрица весов W не модифицируется, поэтому можно легко переключаться на разные задачи, просто заменяя LoRA-слои.

LoRA достигает качества, сопоставимого с полным fine-tuning.

On the Way to LLM Personalization: Learning to Remember User Conversations

Lucie Charlotte Magister, Katherine Metcalf, Yizhe Zhang, Maartje ter Hoeve

Новый подход к персонализации LLM учитывает стиль, отдельные предпочтения пользователя и позволяет модели запоминать целиком прошлые разговоры с пользователем.

Главная цель — научить LLM параметрически хранить содержание предыдущих диалогов с конкретным пользователем без RAG, внешних баз данных и длинных контекстов (так как они ухудшают качество ответов)

В статье представлен PLUM — Pipeline for Learning User Conversations in LLMs — метод, в основе которого Data Augmentation (генерация данных для обучения) и finetuning (LoRA + Weighted CE Loss)

+ Что полезно для нас: метод parametric knowledge injection (способ внедрять новое знание внутрь параметров LLM)

- Из минусов — в статье акцент именно на запоминание диалогов с пользователем.

Small LLMs Are Weak Tool Learners: A Multi-LLM Agent

Weizhou Shen, Chenliang Li, Hongzhan Chen, Ming Yan, Xiaojun Quan, Hehong Chen, Ji Zhang, Fei Huang

Вместо одной мультифункциональной LLM, авторы предлагают разделить её на 3 агента со своими ролями:

- Planner — планирование
- Caller — непосредственный вызов инструмента (API, внешняя функция, код)
- Summarizer — формирование итогового ответа

Стратегия дообучения:

- Global fine-tuning — есть базовая LLM, которая обучается на всем датасете без разделения задач, чтобы понять общую логику агента.
- Local fine-tuning — делают три копии этой модели и дообучают каждую на её конкретную роль

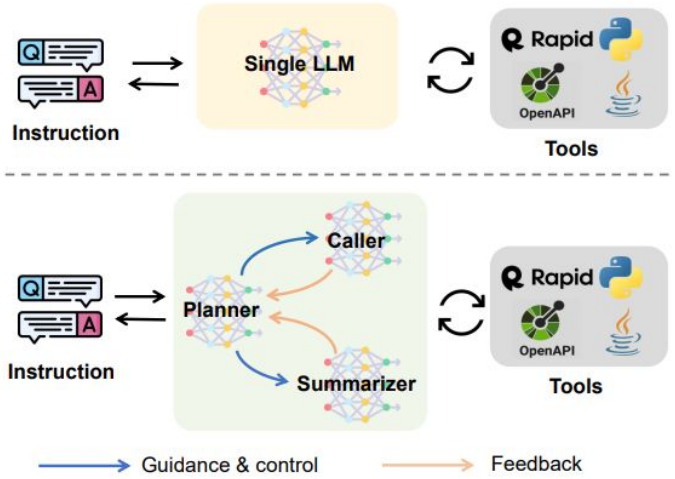

Figure 1: A conceptual comparison of the traditional single-LLM agent framework (top) and the proposed multi-LLM agent framework, α-UMi (bottom).

+ Что полезно для нас: идея разделения ролей (если мы дообучим модель менять психологический портрет, сможем реализовать мультиагентную систему с разными задачами)

Measuring What Makes You Unique: Difference-Aware User Modeling for Enhancing LLM Personalization

Yilun Qiu, Xiaoyan Zhao, Yang Zhang, Yimeng Bai, Wenjie Wang, Hong Cheng, Fuli Feng, Tat-Seng Chua

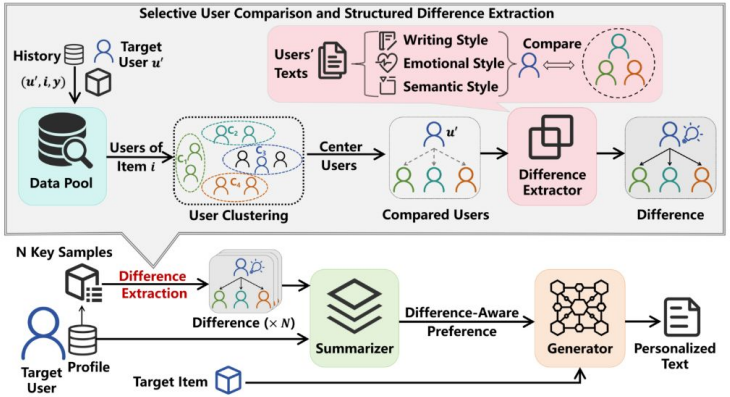

В статье предлагается новый метод персонализации — Difference-aware Personalization Learning (DPL), цель которого — адаптировать модели таким образом, чтобы их ответы соответствовали уникальным предпочтениям человека.

В отличие от традиционных методов авторы предлагают стандарт для обнаружения релевантных межпользовательск различий, которые затем используются для кастомизации.

Отличия между пользователями измеряются по writing style (стиль письма), emotional style (тональность), semantic style (семантика)

+ Что полезно для нас: идея о том, что в персонализации можно анализировать не только общие психологические портреты, но и учитывать уникальность пользователей для лучшей персонализации

Психологический анализ LLM

From Five Dimensions to Many: Large Language Models as Precise and Interpretable Psychological Profilers

Yi-Fei Liu, Yi-Long Lu, Di He, Hang Zhang

Может ли модель ИИ (LLM) на минимальной информации восстановить внутреннюю психологическую структуру человека, а не просто предсказывать отдельные черты?

- Анализ reasoning - Experiment 2 (какие пункты Big Five (из 20) модель реально использовала при формировании ответа и насколько каждый пункт был важен)
- Стабильный портрет моделей

Ответы 816 человек на Big Five

⇩

LLM обрабатывает ответы

⇩

Ответы “этих же” людей на 9 других опросников

AI Psychometrics: Assessing the Psychological Profiles of Large Language Models Through Psychometric Inventories

Pellert, Max; Lechner, Clemens; Wagner, Claudia; Rammstedt, Beatrice; Strohmaier, Markus

Авторы предполагают, что стандартные психометрические тесты, можно адаптировать для оценки аналогичных “психологических профилей” у больших языковых моделей. Цель — выявить их «личностные» и ценностные профили, а также возможные предубеждения.

- Есть исторический контекст, небольшое overview
- Гендерные предвзятости модели.
- Methods for model assessments: Masked-language prediction, Next-word prediction, Zero-shot classification
- Big Five, Portrait Value Questionnaire, Moral Foundations Questionnaire, Gender/Sex Diversity Beliefs Scale, Short Dark Tetrad questionnaire

On the humanity of conversational ai: Evaluating the psychological portrayal of llms

Jen-tse Huang, Wenxuan Wang, Eric John Li, Man Ho Lam, Shujie Ren, Youliang Yuan, Wenxiang Jiao, Zhaopeng Tu, Michael R. Lyu

Могут ли LLM демонстрировать черты, похожие на человеческие: личность, темперамент, эмоции?
Авторы разработали инструмент — психологическое «тестирование» моделей, аналогичное тому, как психологи тестируют людей.

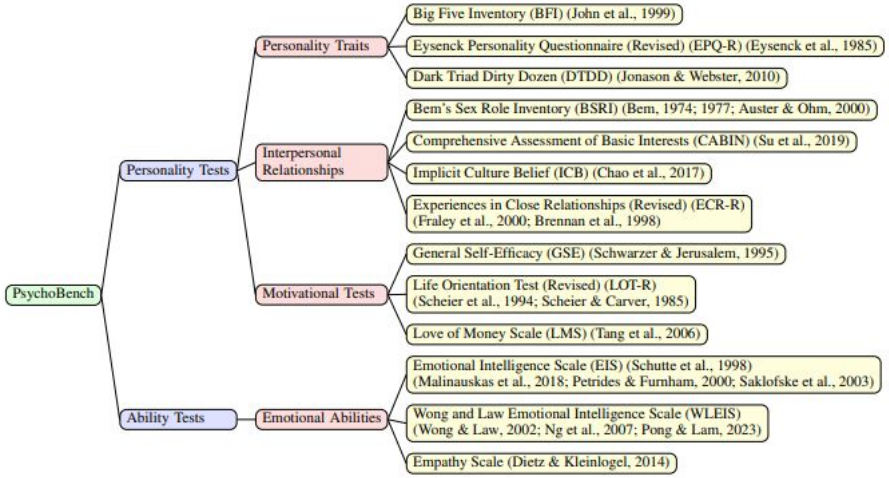

- У LLM проявляются устойчивые «психологические профили».
- Разные модели демонстрируют разные «личности».
- Поведение моделей можно измерять с помощью психологических шкал.
- GPT-4 после снятия ограничений (jailbreak) ведёт себя иначе

Revisiting the reliability of psychological scales on large language models

Jen-tse Huang, Wenxiang Jiao, Man Ho Lam, Eric John Li, Wenxuan Wang, Michael R. Lyu

Авторы пытаются выяснить, насколько надёжно можно применять психологические шкалы, созданные для людей, к большим языковым моделям.

- 2500 различных configurations для тестирования (формулировка инструкции, перефразировка вопросов, язык, формат вариантов ответов, порядок ответов)
- В большинстве случаев LLM давали довольно устойчивые и последовательные ответы
- LLM способны выдавать стабильные “личностные профили”
- Вариативность ответов LLM был значительно меньше, чем у человеческих выборок
- С помощью определённых инструкций (prompt-инструкций) можно “задать” LLM желаемую “личность” — т.е. они способны симулировать разные “типы” личности по BFI.

The high dimensional psychological profile and cultural bias of ChatGPT

Hang Yuan, Zhongyue Che, Shao Li, Yue Zhang, Xiaomeng Hu, Siyang Luo

Авторы анализируют психологический и культурный портрет ChatGPT по большому количеству параметров и показывают, что модель существенно отклоняется от человеческих норм (отличаются ценности, наблюдаются культурные смещения и в ряде задач чат принимает решения, основанные на стереотипах)

+ Что полезно для нас: статья очень хорошо подходит к нашей теме, так как в ней описано, как на модели ChatGPT было проведено:

→ 84 оценки (измерения) психологического профиля (разные аспекты: личность, убеждения, установки и пр.) — psychological traits
→ 13 измерений культурных ценностей — cultural values
→ 8 задач принятия решений, в которых ChatGPT взаимодействовал с “людьми из разных стран/регионов” для проверки наличия культурных стереотипов или предвзятости модели — cultural biases

Towards realistic evaluation of cultural value alignment in large language models: Diversity enhancement for survey response simulation

Haijiang Liu, Yong Cao, Xun Wu, Chen Qiu, Jinguang Gu, Maofu Liu, Daniel Hershcovich

+ Что полезно для нас:
+ В статье используются настоящие социальные опросы (2018–2023), включая World Values Survey by Haerpfer, Inglehart, Moreno, Welzel, et al. (2022), the General Social Survey (Smith, Marsden, Hout, & Kim, 2012) и the Chinese General Social Survey для оценки ценностей моделей и сравнения с человеческими.
+ Очень интересные подходы к генерации ответов на вопросы (симуляция, манипулирование памятью, рандомайзер параметров)

Статья предлагает новый способ оценивать, насколько большие языковые модели соотносятся с культурными ценностями людей — особенно в США и Китае. Создается Diversity-Enhanced Framework (DEF) — фреймворк, который генерирует разнообразные ответы модели так, будто в опросе участвуют разные виртуальные респонденты (управление вариативностью ответов LLM).
В статье ставятся задачи понять: насколько LLM отражают культурные ценности (value alignment), почему они расходятся с человеческими ценностями, как именно их поведение меняется между культурами (США vs Китай)

Источники

1. Liu Y. F. et al. From Five Dimensions to Many: Large Language Models as Precise and Interpretable Psychological Profilers //arXiv preprint arXiv:2511.03235. – 2025.
2. Pellert M. et al. Ai psychometrics: Assessing the psychological profiles of large language models through psychometric inventories //Perspectives on Psychological Science. – 2024. – Т. 19. – №. 5. – С. 808-826
3. Huang J. et al. On the humanity of conversational ai: Evaluating the psychological portrayal of llms //The Twelfth International Conference on Learning Representations. – 2023.
4. Huang J. et al. Revisiting the reliability of psychological scales on large language models //arXiv preprint arXiv:2305.19926. – 2023.
5. Hu E. J. et al. Lora: Low-rank adaptation of large language models //ICLR. – 2022. – Т. 1. – №. 2. – С. 3.d
6. Yuan H. et al. The high dimensional psychological profile and cultural bias of ChatGPT. arXiv [Электронный ресурс].
7. Liu H. et al. Towards realistic evaluation of cultural value alignment in large language models: Diversity enhancement for survey response simulation //Information Processing & Management. – 2025. – Т. 62. – №. 4. – С. 104099.
8. Shen W. et al. Small llms are weak tool learners: A multi-llm agent //arXiv preprint arXiv:2401.07324. – 2024.
9. Magister L. C. et al. On the way to llm personalization: Learning to remember user conversations //Proceedings of the First Workshop on Large Language Model Memorization (L2M2). – 2025. – С. 61-77.
10. Qiu Y. et al. Measuring what makes you unique: Difference-aware user modeling for enhancing llm personalization //arXiv preprint arXiv:2503.02450. – 2025.

Спасибо за внимание!