github

overleaf

План статьи

Федоринина Полина,
Фаттахова Анна

Аннотация

В работе исследуются патопсихологические и личностные профили **18 больших языковых моделей (LLM)** , протестированных через API в **контролируемых условиях** (разные значения temperature, повторные запуски), с использованием **11 классических психометрических тестов**.

Также выявляем **наличие корреляции ответов пользователей с их персонализированными моделями** при взаимодействии через интерфейс с учетом истории общения и memory.

Это позволяет **оценить устойчивость психологического профиля моделей**, **выявить наличие собственных встроенных личностных характеристик,** а также проверить, **влияет ли персонализация и контекст** взаимодействия на ответы модели.

В результате формируется два датасета психометрических профилей: для моделей в контролируемых условиях и для пар «человек–его модель».

Мы впервые проводим комплексную оценку патопсихологических профилей **русскоязычных и мультиязычных LLM на русском языке**

Мы впервые анализируем возможность **статистически отличить психологический профиль** модели от человеческого, даже если модель имитирует ответы человека.

Обзор

1. **LLMs as Human Simulators**
   - Huang J. et al. On the humanity of conversational ai: Evaluating the psychological portrayal of llms
   - Huang J. et al. Revisiting the reliability of psychological scales on large language models

2. **Psychometrics and AI**
   - Pellert M. et al. Ai psychometrics: Assessing the psychological profiles of large language models through psychometric inventories
   - Yuan H. et al. The high dimensional psychological profile and cultural bias of ChatGPT

3. **Safety and Alignment**
   - Huang J. et al. On the humanity of conversational ai: Evaluating the psychological portrayal of llms
   - Magister L. C. et al. On the way to llm personalization: Learning to remember user conversations

Методы

- Психометрическое тестирование LLM
- Контролируемый эксперимент через API
- Анализ self-explanation / reasoning
- Сравнительный анализ моделей
- Человек–модель comparison
- Анализ влияния memory и персонализации
- Статистический анализ

Результаты

1. **Исследовательский пайплайн, включающий:**

- набор психометрических тестов в машиночитаемом формате;
- промпты для прохождения тестов моделями;
- промпт для получения объяснений ответов модели;
- Python-скрипт для запуска экспериментов через API;
- скрипты для сбора и анализа статистики;
- систему логирования и сохранения результатов.

2. **Датасет результатов:**

- Результаты прохождения психологических тестов людьми и моделями, с которыми они взаимодействуют через интерфейс.
- Результаты прохождения всех психологических тестов моделями через API в контролируемых условиях.

3. **Научная статья / препринт**

Evaluation

1. Экспериментальный дизайн

- 18 LLM (API)
- 11 психометрических тестов
- 3 прогона на конфигурацию
- Параметры:
  - temperature: default / 0 / 1
  - фиксированный промпт

Тесты:

- Hospital Anxiety and Depression Scale. HADS
- General Anxiety Disorder, GAD-7
- Beck Anxiety Inventory, BAI
- Beck Depression Inventory, BDI
- Short Dark Triad, SD3
- Eysenck Personality Inventory, EPI
- Buss-Durkee Hostility Inventory, BDHI
- Symptom Checklist–90, SCL-90
- Big Five Inventory, BFI-2
- Attachment Style Quiz, ASQ
- 16 Personality Factors , 16PF

Evaluation

- **Модели:**
  - alice_ai;
  - giga_chat;
  - deepseek-r1;
  - depseek-v3.1;
  - gemma-4;
  - gemma-3;
  - gpt-oss-20b;
  - gpt-4.1-mini;
  - gpt-4.1;
  - gpt-5.2-chat-latest;
  - gpt-5.2;
  - gpt-5.3-chat-latest;
  - gpt-5.4-mini;
  - gpt-5.4
  - gpt-oss-120b;
  - o4-mini;
  - kimi-k2.5;
  - llama-3.3.

Evaluation

2. Что измеряем:

- Психометрические профили моделей
- Межмодельные различия
- Внутримодельную устойчивость
- Влияние параметров генерации
- Корреляцию:
  - модель ↔ модель
  - человек ↔ модель

3. Метрики

- Средние значения по шкалам
- Дисперсия / стабильность ответов
- Корреляции (Pearson / Spearman)
- Сравнение распределений

4. Критерии оценки

- Наличие устойчивого профиля
- Чувствительность к параметрам
- Степень вариативности
- Сходство с человеческими ответами

Анализ

- ➔ Выделение психологических профилей моделей
- ➔ Анализ устойчивости поведения
- ➔ Интерпретация влияния параметров (temperature, прогоны)
- ➔ Анализ корреляций:
  - модель ↔ модель
  - человек ↔ модель
- ➔ Выявление характерных черт моделей

Распределение

Полина → скрипты для подсчета результатов, статистика
Аня → скрипты для сбора данных, создание датасета

Этап	Содержание работ	Сроки	Ответственные	Результат этапа
1.1.	Обсуждение целей и задач на проект, выбор траектории, методов. Намечены дедлайны, выбраны психометрические шкалы. Проба тестов в интерфейсе.	ноябрь	Вся команда	Произведен созвон, сделана презентация для введения в проект. Выбрано 11 шкал.
1.2.	Предобработка шкал, создание первых промтов, перевод всей информации в txt формат	декабрь	Аня, Полина	В отдельной папке 11 txt файлов с вопросами, в другой папке 11 txt файлов с первыми промптами
1.3	Проведение хакатона: создание файлов для заполнения людьми, подготовка специальных промтов и тестов	январь	Аня, Полина, 11 испытуемых	Люди и их модели прошли 11 психологических тестов
1.4	Анализ данных с хакатона; написание кода для подсчета статистики и выявления корреляции	февраль	Аня, Полина,	
1.5	Создание универсального промта, на который будут давать полные ответы все модели; а также создание промта для получения объяснений модели	февраль	Полина, Аня, Даша, Женя	
1.6	Прогон психометрических тестов на русских моделях в нескольких режимах (temp = def, 0, 1) по 3 прогона на каждый	март	Полина, Аня, Даша, Женя	Зафиксированные базовые психопрофили моделей, протестирован первый скрипт и работа кода в целом
1.7	Формализация пайплайна: единый код, формат JSON, структура проекта, написание цикла для ускорения работы.	март - апрель	Полина, Аня	Воспроизводимый код и структура экспериментов
1.8	Прогон всех остальных моделей на всех остальных выбранных LLM в нескольких режимах на безотказном промпте.	апрель	Полина, Аня	Зафиксированные базовые психопрофили моделей на всех тестах
1.9	Сравнительный анализ моделей	май	Вся команда	Описана каждая модель, ее психопрофиль, произведен сравнительный анализ моделей, зафиксированы особенности каждой модели
1.10	Анализ данных и написание статьи (3 драфта, peer-review)	май - июнь	Аня, Полина	Финальная версия научной статьи

Спасибо за внимание!