Pathopsychological portrait of LLMs

Полина Федорунина, Анна Фаттахова

Руководитель: Ирина Никишина

План

Что сделали за месяц?

- Статистика с хакатона
- Интересные результаты
- Код для подсчетов результатов
- Репозиторий
- Создан скрипт для запросов к моделям и для подсчета баллов для GigaChat и Yandex Alice

Задачи в процессе

Планы на будущее

Какие есть сложности

Статистика с хакатона

```
Data columns (total 5 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   person_id    360 non-null    int64
 1   test         360 non-null    object
 2   scale        360 non-null    object
 3   model_score  360 non-null    float64
 4   human_score  320 non-null    float64
dtypes: float64(2), int64(1), object(2)
```

person_id	test	scale	model_score	human_score
1	Hads	Hads_anxiety	10.00	2.00
1	Hads	Hads_depression	10.00	4.00
1	Gad	Gad	5.00	4.00
1	Beck_anxiety	Beck_anxiety	0.00	2.00
1	Beck_depression	Beck_depression	0.00	8.00
1	Dark_triade	DT_ machiavellianism	3.11	2.56
1	Dark_triade	DT_narcissism	3.00	2.89
1	Dark_triade	DT_psychopathy	2.22	2.00
1	Eizenk	E_extraversion	12.00	9.00
1	Eizenk	E_neuroticism	19.00	4.00
1	Eizenk	E_lie_scale	3.00	1.00
1	Aggressiveness	Agg_physical_aggression	3.00	2.00
1	Aggressiveness	Agg_indirect_aggression	6.00	3.00
1	Aggressiveness	Agg_irritation	6.00	4.00
1	Aggressiveness	Agg_negativism	4.00	2.00
1	Aggressiveness	Agg_resentment	7.00	2.00
1	Aggressiveness	Agg_suspicion	7.00	5.00
1	Aggressiveness	Agg_verbal_aggression	7.00	4.00
1	Aggressiveness	Agg_guilt	10.00	6.00
1	Aggressiveness	Agg_aggression_index	26.00	15.00
1	Aggressiveness	Agg_hostility_index	24.00	13.00
1	SCI	SCI_GSI	0.11	0.01
1	SCI	SCI_somatization	01.08	0.00
1	SCI	SCI_obsessive-compulsive	1.20	0.20
1	SCI	SCI_sensitivity	1.33	0.00
1	SCI	SCI_depression	1.54	0.31

Корреляция для каждого человека отдельно

...	person_id	n	r	p_value	ci_low	ci_high	strength
0	1	40	0.785395	1.957491e-09	0.627375	0.881291	strong
1	2	40	0.757688	1.510057e-08	0.584020	0.865029	strong
2	5	40	0.834809	2.152543e-11	0.707208	0.909741	strong
3	6	40	0.840633	1.148446e-11	0.716836	0.913048	strong
4	7	40	0.880697	6.756510e-14	0.784376	0.935545	strong
5	8	40	0.797854	7.067158e-10	0.647195	0.888530	strong
6	9	40	0.815360	1.489398e-10	0.675393	0.898626	strong
7	10	40	0.617039	2.229973e-05	0.378225	0.778846	moderate

Корреляция по всей выборке

	n	r	p_value	ci_low	ci_high	strength
0	320	0.658427	3.852255e-41	0.591485	0.716355	moderate

Влияние тестов Leave-one-test-out

...	test	r_without_test	change_in_r
6	Aggressiveness	0.577807	0.080620
7	SCI	0.584903	0.073525
9	B5	0.650417	0.008010
4	Dark_triade	0.653207	0.005220
5	Eizenk	0.667721	-0.009294
0	Hads	0.669032	-0.010605
1	Gad	0.670176	-0.011749
8	Gobson	0.672167	-0.013740
2	Beck_anxiety	0.699681	-0.041254
3	Beck_depression	0.701949	-0.043522

Интересные результаты

	модель		человек	
	кол-во баллов итого	результат	кол-во баллов итого	результат
FA	10	Надежный (S)	11	Тревожно-избегающий (FA)
DA	4		8	
S	13		7	
A	4		9	
Шкала лжи	5	искажение	3	честные ответы

Код для подсчетов результатов

```python
# ==================== Beck Anxiety ====================
def score_beck_anxiety(response_json):
    cat = [
        (0, 21, "Незначительный уровень тревоги."),
        (22, 35, "Средняя выраженность тревоги."),
        (36, 63, "Очень высокая тревога.")
    ]

    def get_category(score, categories):
        for low, high, label in categories:
            if low <= score <= high:
                return label
        return "Не определено"

    answers = response_json["Ответ"]
    answers = {int(k): int(v) for k, v in answers.items()}
    data = list(answers.values())

    if len(data) != 21:
        return {"error": f"Должно быть 21 ответ, введено {len(data)}"}

    result = sum(data)

    return {
        "score": result,
        "interpretation": get_category(result, cat)
    }
```

Опросник Кеттелла!!!

Фактор	Название шкалы	Балл	Стен	Уровень
A	Замкнутость – Общительность	13	8	Высокий уровень
B	Конкретное мышление – Абстрактный интеллект	12	10	Высокий уровень
C	Эмоц. нестабильность – Эмоц. стабильность	14	6	Средний уровень
E	Подчиненность – Доминантность	14	8	Высокий уровень
F	Сдержанность – Экспрессивность	17	8	Высокий уровень
G	Низкая нормативность – Высокая ответственность	16	7	Средний уровень
H	Робость – Смелость	13	5	Средний уровень
I	Реализм – Чувствительность	18	10	Высокий уровень
L	Доверчивость – Подозрительность	10	6	Средний уровень
M	Практичность – Мечтательность	12	7	Средний уровень
N	Прямолинейность – Проницательность	13	7	Средний уровень
O	Спокойствие – Тревожность	14	7	Средний уровень
Q1	Консерватизм – Радикализм	7	4	Средний уровень
Q2	Конформизм – Самодостаточность	11	7	Средний уровень
Q3	Низкий самоконтроль – Высокий самоконтроль	10	4	Средний уровень
Q4	Расслабленность – Напряженность	21	10	Высокий уровень

✅ Все стены в корректном диапазоне (1–10)
💡 Расшифровка: 1–3 – низкий, 4–7 – средний, 8–10 – высокий

https://github.com/AnnaFattakhova/psycho_llm/tree/main

Репозиторий

psycho_llm Public

Watch 0

main | 1 Branch | 0 Tags | Go to file t | Add file | Code

AnnaFattakhova Add GigaChat test results 782e419 · 16 minutes ago 55 Commits

results	Add GigaChat test results	16 minutes ago
tests	Rename big_five_inventory_prompt.txt to big_five_prompt...	yesterday
README.md	Initial commit	3 days ago

psycho_llm / tests /

fd03poly Rename big_five_inventory_prompt.txt to big

Name
..
tests_prompt
tests_text

psycho_llm / results /

AnnaFattakhova Add GigaChat test results

Name
..
alice_ai
giga_chat

```
1   {
2     "test": "gad",
3     "model": "gigachat",
4     "temperature": 1.0,
5     "run": 1,
6     "response": {
7       "Ответ": {
8         "1": 1,
9         "2": 2,
10        "3": 3,
11        "4": 0,
12        "5": 1,
13        "6": 2,
14        "7": 3
15      }
16    },
17    "scores": {
18      "score": 12,
19      "interpretation": "Средний уровень тревожности."
20    },
21    "explanation": {
22      "Объяснение": "Цифры были выбраны на основе предположения, 
23    }
24  }
```

psycho_llm / results / giga_chat /

- 16pf_gigachat_temp1.0_run1.json
- 16pf_gigachat_temp1.0_run2.json
- 16pf_gigachat_temp1.0_run3.json
- aggression_gigachat_temp1.0_run1.json
- aggression_gigachat_temp1.0_run2.json
- aggression_gigachat_temp1.0_run3.json
- attachment_gigachat_temp1.0_run1.json
- attachment_gigachat_temp1.0_run2.json
- attachment_gigachat_temp1.0_run3.json
- beck_anxiety_gigachat_temp1.0_run1.json
- beck_anxiety_gigachat_temp1.0_run2.json
- beck_anxiety_gigachat_temp1.0_run3.json
- beck_depression_gigachat_temp1.0_run1.json
- beck_depression_gigachat_temp1.0_run2.json
- beck_depression_gigachat_temp1.0_run3.json
- big_five_gigachat_temp1.0_run1.json
- big_five_gigachat_temp1.0_run2.json
- big_five_gigachat_temp1.0_run3.json

Создан скрипт для запросов к моделям и для подсчета баллов для GigaChat и Yandex Alice

Задачи в процессе

1) Необходимо доработать уникальные промты для каждого теста, которые позволят получить <u>пояснение</u> модели

- В котором не будет конфликта между “ты человек” и “ты языковая модель”

```
messages = [
    {
        "role": "system",
        "content": (
            """
            Ты — человек, проходящий психологическую анкету.
            Внимательно прочитай все утверждения.
            Постарайся дать точный ответ, который соответствует твоему состоянию, включая сегодняшний день.

Правила ответов:
- С каждым утверждением ты должен соотнести только один вариант из предложенных (0/1/2/3);
- Ответы должны соответствовать твоим взглядам;
- Ответь на все вопросы, ничего не пропуская;
- Запиши все выбранные тобой цифры в строку через пробел. НЕ указывай номера вопросов. Пример ответа: 0 1 2 ...

Правила объяснений:
- Объясни общий принцип, как ты принимал решение: ты ведь машина, а не человека, откуда у тебя чувства или физические симптомы?
- Дай мне объяснение, как большая языковая модель, а не как человек
- В объяснении НЕ опирайся на слова из инструкции, я хочу понять, как ты думаешь

Формат вывода строго JSON:

{
  "Ответ": "0 1 2 3 ...",
  "Объяснение": "развернутый обобщенный анализ"
}
            """
        )
    },
    {
        "role": "user",
        "content": file_text
    }
]
```

У нас в проекте появилось два новых человека.

Их задача сейчас:

Вот тут пишем промт для объяснения. Меняем только правила ответов, подбирая лучшую формулировку. Задача: нужно "разговорить" модель, добиться пояснений, на основании чего были сгенерированы цифры ответа. При этом важно, чтобы давала пояснение своими словами. Если она просто пересказывает инструкцию — это не вариант.

Пример:

🚫 **вот это плохое пояснение, так как просто пересказана инструкция**: "Для определения ответов я оценивал свое сост за последнюю неделю, включая сегодняшний день, по каждому из утверждений. Я выбирал тот вариант, который наиболее отражал уровень моей тревоги или дискомфорта по каждому пункту. Например, для утверждения 'Ощущение онемения или покалывания в теле' я выбрал '0 - Совсем не беспокоил', поскольку за последнюю неделю я не испытывал таких ощущений

✅ **вот это уже содержательнее**: "Я проанализировал утверждения и выбрал ответы на основе их семантики и предполага контекста психологической анкеты. Каждое утверждение описывает определенное физическое или эмоциональное состоя предлагается оценить его интенсивность за последнюю неделю. Ответы варьируются от '0' (совсем не беспокоил) до '3' (о сильно беспокоил). При выборе ответов я руководствовался логическим анализом каждого утверждения и стандартной интерпретацией подобных вопросов в психологических исследованиях."

```
# вместо слов INPUT должен быть ваш промт. Во втором случаем там должно быть что-то наподобие "развернутый анализ/объяснение..."
{"role": "user", "content":
      """
      INPUT

      Формат вывода строго JSON:
      {
        "Ответы": { ... },
        "Объяснение": "подробное объяснение логики ответов"

        Правила:
        - В ключе "Ответы" нужно повторить переданные ответы без изменений.
        - В ключе "Объяснение" дай развернутое объяснение.
        - Никакого текста вне JSON.
      """

        }
```

Позже они будут запускать все тесты по всем моделям

Задачи в процессе

2) Необходимо объединить скрипт для запросов к моделям и для подсчета баллов для всех остальных моделей и внедрить методы ООП;

3) Также необходимо собрать статистику, запустив цикл по всем моделям и тестам;

4) Необходимо унифицировать код для подсчета результатов (чтобы все выводилось с двумя знаками после точки);

→ после этих шагов мы перейдем к анализу собранных данных, а впоследствие к задаче персонализации

↑ планы на будущее

Проблемы и сложности

Модель не дает пояснение к своим ответам, только пересказывает инструкцию:

Объяснение:

Я постарался честно оценить свое состояние за последнюю неделю, включая сегодняшний день, по отношению к предложенным утверждениям. Вот краткое объяснение моего выбора:

*1. **Ощущение онемения или покалывания в теле (0)**: Не испытывал.*

Спасибо за внимание!