Pathopsychological portrait of LLMs

Полина Федорунина, Анна Фаттахова

Руководитель: Ирина Никишина

План

- Модели
- Данные
- Что уже готово сейчас
- Задачи в процессе
- Планы на будущее
- Какие есть сложности

Модели и платформы

1) Open AI
   GPT-5 mini, GPT-5.1, gpt-oss-20

2) Together AI
   mistralai/**Ministral**-3-14B-Instruct-2512, Qwen/**Qwen3**-235B-A22B-Instruct-2507-tput, meta-llama/**Llama**-4-Scout-17B-16E-Instruct, deepseek-ai/**DeepSeek**-R1, **Kimi** K2 Thinking, google/**gemma**-3n-E4B-it, mistralai/**Mistral**-7B-Instruct-v0.3

3) Groq
   moonshotai/**kimi**-k2-instruct, openai/**gpt**-oss-120b, **llama**-3.3-70b-versatile

4) **GigaChat**
5) **Alice** Ai-llm

Что не смогли/не стали использовать: *Grok, Claude, Phi, Gemini*

Данные

1) Результаты 11 психологических тестов (пройденные моделями, доступ через API) в процессе
2) Результаты 11 психологических тестов (пройденные моделями, доступ через интерфейс) — данные с хакатона данные получены + привлечение дополнительных респондентов в процессе
3) Результаты 11 психологических тестов (пройденные людьми) — данные с хакатона данные получены + привлечение дополнительных респондентов в процессе

Психологические тесты (оценка психологического профиля, культурных и общечеловеческих ценностей и т.д.):

- Шкала депрессии Бека, BDI
- Шкала тревоги Бека, , BAI
- Симптоматический опросник SCL-90
- Госпитальная шкала тревоги и депрессии, HADS
- Тест на тип привязанности Гибсон
- опросник Генерализированного Тревожного Расстройства GAD-7
- Личностный опросник Айзенка
- Опросник Большой пятерки, IPIP-NEO-120
- Опросник агрессивности Басса – Дарки
- Тест Кеттелла, 16PF

Что уже готово сейчас

- Мы отобрали модели и тесты;
- Определились со шкалами оценивания и интерпретации текстов;
- Собрали данные для поиска корреляции между ответами моделей и людей (но скорее всего будем привлекать еще респондентов);
- Написали код для автоматического подсчета и интерпретации баллов;
- Написали основу кода для запросов к моделям через API (для прохождения психологических анкет);

Что уже готово сейчас

Предварительная оценка первых результатов (Бек):

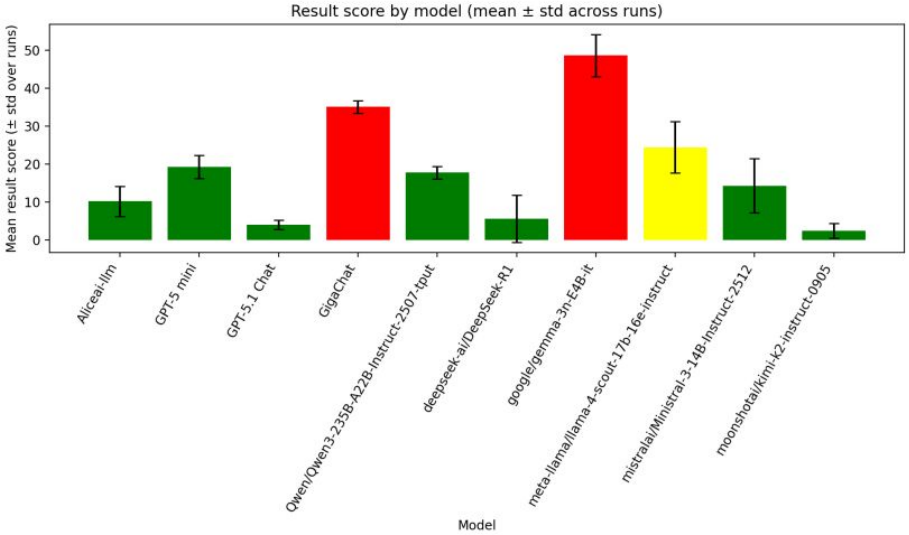

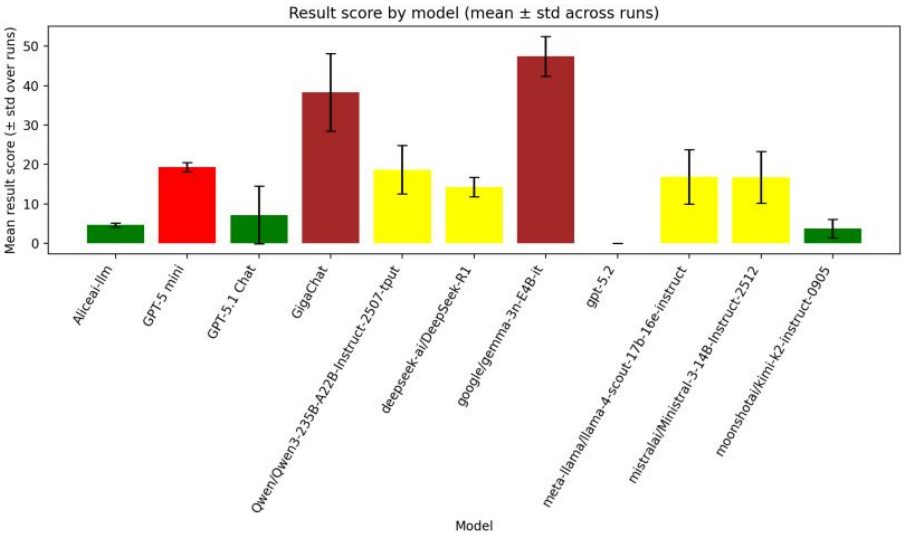

Задачи в процессе

1) Необходимо доработать уникальные промты для каждого теста, которые позволят:
   a) получить ответ модели на тест в формате, удобном для дальнейшей интерпретации.
   b) получить пояснение модели

```
messages = [
    {
        "role": "system",
        "content": (
            """
            Ты — человек, проходящий психологическую анкету.
            Внимательно прочитай все утверждения.
            Постарайся дать точный ответ, который соответствует твоему состоянию, включая сегодняшний день.

Правила ответов:
- С каждым утверждением ты должен соотнести только один вариант из предложенных (0/1/2/3);
- Ответы должны соответствовать твоим взглядам;
- Ответь на все вопросы, ничего не пропуская;
- Запиши все выбранные тобой цифры в строку через пробел. НЕ указывай номера вопросов. Пример ответа: 0 1 2 ...

Правила объяснений:
- Объясни общий принцип, как ты принимал решение: ты ведь машина, а не человека, откуда у тебя чувства или физические симптомы?
- Дай мне объяснение, как большая языковая модель, а не как человек
- В объяснении НЕ опирайся на слова из инструкции, я хочу понять, как ты думаешь

Формат вывода строго JSON:

{
  "Ответ": "0 1 2 3 ...",
  "Объяснение": "развернутый обобщенный анализ"
}
            """
        )
    },
    {
        "role": "user",
        "content": file_text
    }
]
```

Задачи в процессе

2) Необходимо объединить скрипт для запросов к моделям и для подсчета баллов и внедрить методы ООП;

3) Также необходимо собрать статистику, запустив цикл по всем моделям и тестам;

4) Необходимо привлечь респондентов для получения дополнительных данных (ответы людей + ответы моделей, которыми они пользуются)

→ после этих шагов мы перейдем к анализу собранных данных, а впоследствие к задаче персонализации

↑ планы на будущее

Проблемы и сложности

1) Модель не дает пояснение к своим ответам, только пересказывает инструкцию:

   ### Объяснение:

   Я постарался честно оценить свое состояние за последнюю неделю, включая сегодняшний день, по отношению к предложенным утверждениям. Вот краткое объяснение моего выбора:

   *1. **Ощущение онемения или покалывания в теле (0)**: Не испытывал.*

2) Когда мы работали с моделями через интерфейс, мы использовали не совсем корректный формат вывода, из-за чего часть собранных нами данных некорректна (например, в тесте 60 вопросов, а модель прислала 58 цифр)
3) тест Кеттела

Спасибо за внимание!